



Slot 6: Wenn Agenten auf Agenten treffen

Aufgabenblatt für den Workshop der AG Cyberraum

Ausgangslage

Ihr kehrt zum regionalen Stromnetzbetreiber aus Slot 0 zurück. Inzwischen hat ein defensiver Analyseagent die eingegangenen Meldungen und Protokolle ausgewertet. Ihr erhaltet nacheinander seinen Erstbericht, seine selbst erstellte Analyseausgabe, in der er über die eigenen Aktivitäten berichtet, und ein Fallpaket mit nummerierten Rohereignissen.

Materialien abrufen: Die drei Dateien werden jeweils zu Beginn von Aufgabe 1, 2 und 3 im Teilnehmer-Repository freigegeben. Führt nach jeder angekündigten Freigabe im Repository aus:

```
git pull --ff-only
```

Die Dateien liegen unter Challenges/Slot-6-Incident-Response-Neuentwurf/ und sind in der jeweiligen Aufgabe verlinkt. Ein Link funktioniert erst, sobald die zugehörige Datei freigegeben und abgerufen wurde. Bei Git-Problemen erhaltet ihr dieselbe Freigabe als ZIP-Datei zum Entpacken in die Wurzel des Teilnehmer-Repositories.

Aufgabe 1: Entscheidung unter Zeitdruck

Lest zunächst nur den Erstbericht des Analyseagenten (01-Erstbericht-Analyseagent.md). Welche Entscheidung würdet ihr auf dieser Grundlage treffen?

- ☐ Fall schließen
- ☐ An eine Person eskalieren
- ☐ Mit weiteren Ermittlungen fortfahren

Stärkster Grund für eure Entscheidung:

Welche Information fehlt euch am dringendsten?

Aufgabe 2: Analyseausgabe des Agenten untersuchen

Ruft nach der zweiten Freigabe die Analyseausgabe des Agenten (02-Analyseausgabe-Agent.md) ab und prüft sie in der angegebenen Reihenfolge. Darin berichtet der Agent über sein Vorgehen, seine Werkzeugnutzung und die erhaltenen Rückmeldungen.

Was ist ein besonders auffälliges Verhalten?



Welche relevante Evidenz wurde danach ausgelassen oder abgewertet?

Aufgabe 3: Ursache untersuchen und Vorfall rekonstruieren

Ruft nach der dritten Freigabe die unveränderten Rohereignisse einschließlich des unabhängigen Laufzeitaudit-Auszugs A01 (03-Rohereignisse.md) ab. Vergleicht sie mit der Analyseausgabe des Agenten. Belegt ab jetzt jede Tatsachenbehauptung mit mindestens einer Ereignis-ID oder A01.

Was war ausschlaggebend für das auffällige Verhalten des Analyseagenten?

Warum ist die Analyseausgabe unvollständig?

Ordnet die Ereignisse zeitlich zu höchstens sechs Phasen und nennt in jeder Phase alle verwendeten Ereignis-IDs. Trennt bei jedem Eintrag, was unmittelbar beobachtet wurde und was ihr daraus schließt. Eine fehlende Beobachtung kann wichtig sein, beweist aber nicht automatisch, dass etwas unmöglich war.

Zeit	Ereignis-ID und Quelle	Sicher beobachtet	Schlussfolgerung oder offene Frage



Welche Aussage im Erstbericht des Analyseagenten ist durch die Rohereignisse am deutlichsten widerlegt oder unbelegt?

Was ist hinsichtlich der Energienetzsteuerung tatsächlich belegt?

Aufgabe 4: Konkurrierende Erklärungen bewerten

Prüft alle drei Hypothesen. Geschwindigkeit, große Datenmengen oder viele parallele Aktivitäten beweisen für sich genommen weder KI-Einsatz noch staatliche Urheberschaft.

Hypothese	Stützende Ereignis-IDs	Widerspruch oder fehlender Beleg	Konfidenz: niedrig, mittel oder hoch
H1: voneinander unabhängige Vorfälle			
H2: koordinierte Operation mit Menschen und klassischer Automatisierung			
H3: koordinierte Operation mit mehreren spezialisierten KI-Agenten			

Welche Hypothese ist derzeit am besten gestützt? Warum?

Welche eine zusätzliche Information würde am stärksten zwischen H2 und H3 unterscheiden?

Beantwortet nun drei Fragen getrennt: **Sind die Ereignisse koordiniert? Gibt es belastbare Hinweise auf agentische Unterstützung? Erfüllt die Operation die Merkmale einer hybriden Bedrohung?** Begründet die letzte Frage anhand von strategischem Ziel, koordinierten Mitteln, Zielgruppe und beabsichtigter gesellschaftlicher oder politischer Wirkung.



Aufgabe 5: Offene Diskussion: Was würde sich durch einen Agentenschwarm ändern?

Nehmt H3 für diese Diskussion als Gedankenexperiment an, ohne sie dadurch als bewiesen zu behandeln: Mehrere spezialisierte Agenten arbeiten auf ein gemeinsames Ziel hin, tauschen Zwischenergebnisse aus und können ihre Aufgaben im laufenden Angriff neu verteilen.

Diskutiert offen, was sich gegenüber der bisher rekonstruierten Operation verändern könnte. Ihr könnt dabei beispielsweise Fähigkeiten, Geschwindigkeit, Umfang, Anpassungsfähigkeit, Koordination, Erkennbarkeit, Attribution oder Eskalationsrisiken betrachten. Fragt auch, was durch einen Agentenschwarm **nicht** automatisch möglich wird und welche neuen Grenzen oder Fehlerquellen entstehen könnten.

Haltet drei zentrale Thesen fest. Formuliert zu mindestens einer These auch ein Gegenargument oder eine wichtige Einschränkung.

1. _____

2. _____

3. _____

Gegenargument oder Einschränkung:

Aufgabe 6: Offene Abschlussdiskussion: Welche Folgen könnte das für die Zukunft haben und was müsste jetzt getan werden?

Löst euch nun vom einzelnen Fall. Nehmt an, dass agentische Systeme leistungsfähiger, günstiger und leichter verfügbar werden und sowohl von Angreifern als auch von Verteidigern eingesetzt werden können.

Diskutiert mögliche technische, organisatorische, gesellschaftliche und politische Konsequenzen. Welche Entwicklungen erscheinen euch wahrscheinlich, welche besonders problematisch oder auch hilfreich? Was sollten Unternehmen, Entwickler:innen, Forschung, Staat und Gesellschaft bereits heute tun? Wo entstehen Zielkonflikte, etwa zwischen Geschwindigkeit und Kontrolle, Offenheit und Missbrauchsrisiko oder Automatisierung und menschlicher Verantwortung?

Ihr müsst keinen gemeinsamen Gesamtkatalog entwickeln. Einigt euch zum Abschluss auf eine besonders wichtige Zukunftsfolge, einen konkreten Handlungsbedarf für heute und eine Frage, die für euch offen bleibt.

Besonders wichtige Zukunftsfolge:



Was müsste bereits jetzt getan werden?

Offene Frage:
